

SOUTENANCE PROJET - DATA ENGINEERING

Architecture d'un Pipeline Data Moderne sur Azure

Ingestion, Traitement distribué via Databricks (Medallion) & Analyse décisionnelle Power BI

Auteur : Étudiant Data Analyst

Technologies : Azure ADF • ADLS Gen2 • Databricks • Spark SQL • Power BI

Contexte & Objectifs

Pourquoi moderniser la chaîne de traitement décisionnelle d'une entreprise du retail ? Réponse à travers ce projet de bout en bout.

La Problématique & Les Objectifs

Le Contexte Retail

Une entreprise de retail souhaite surmonter la fragmentation de ses données (ventes, magasins, stocks, clients). Les processus manuels actuels entraînent des goulots d'étranglement, un manque de cohérence et une latence critique dans l'aide à la décision.

Le besoin : Un flux de données unifié, automatisé, capable d'ingérer et d'analyser en continu des sources hétérogènes (SQL & API).

Objectifs de la Solution

Automatisation : Configurer un orchestrateur robuste avec Azure Data Factory pour l'extraction quotidienne.

Architecture Medallion : Segmenter le stockage en couches Bronze, Silver, et Gold pour assurer la qualité.

Performance : Tirer parti de Databricks et de la puissance d'Apache Spark pour traiter les données volumineuses en un temps record.

Ingestion & Architecture Cloud

Mise en place de la source relationnelle Azure SQL Database, de l'API JSON publique, et orchestration du stockage ADLS Gen2.

Cartographie Des Données Sources

Source	Type d'infrastructure	Données stockées	Format initial	Méthode d'ingestion
Transactions	Azure SQL Database	Historique des achats retail	Relationnel SQL	Azure Data Factory (Copy Activity)
Products	Azure SQL Database	Catalogue, prix et catégories	Relationnel SQL	Azure Data Factory (Copy Activity)
Stores	Azure SQL Database	Localisation et taille des points de vente	Relationnel SQL	Azure Data Factory (Copy Activity)
Customers	API Externe (GitHub JSON)	Fiches profils et segments clients	JSON non-structuré	ADF Web Activity / Rest API

* Toutes les données ci-dessus sont converties au format unifié **Parquet** dès leur ingestion dans la couche Bronze.


Architecture & Ingestion ADF

Orchestration par Azure Data Factory

Un pipeline ADF est configuré pour rapatrier de manière unifiée nos 4 sources distinctes vers la couche **Bronze** d'ADLS Gen2.

Points clés de l'ingestion :

- **Linked Services** : Connexions sécurisées vers Azure SQL et l'API HTTPS publique.
- **Datasets** : Définition des structures d'entrée et de sortie.
- **Copy Activities** : Extraction parallélisée et conversion instantanée en Parquet.



Le Traitement de Données

Présentation du cœur du système : la transformation Medallion avec Databricks & PySpark.


L'Architecture Medallion

Garantir la Qualité par Étapes

Bronze (Données brutes) : Historique brut conservé tel quel. Format Parquet optimisé pour l'écriture rapide.

Silver (Données nettoyées) : Typages forcés (Cast), dédoublonnage, jointure globale des tables et création d'indicateurs (ex: total_amount). Écrit en format Delta.

Gold (Agrégats Business) : Tables agrégées et optimisées pour le requêtage BI. C'est la couche consommée directement par Power BI.



Phase Silver : Traitement Databricks

 **Montage du Data Lake (Mount)** : Connexion de Databricks à ADLS Gen2 via l'utilisation d'un token d'accès ou d'un Service Principal pour l'accès aux répertoires.

 **Jointures Multi-Sources** : Fusion des DataFrames de transactions, produits, magasins et clients pour obtenir une vue dénormalisée complète à 360°.


 **Nettoyage Spark SQL** : Cast des types (Dates, Décimaux), élimination stricte des doublons basés sur la clé de transaction unique et traitement des valeurs manquantes.

 **Ajout d'indicateurs calculés** : Implémentation du calcul métier direct à l'échelle :

$$\text{total_amount} = \text{quantity} \times \text{price}$$

Phase Gold & Optimisation Des Requêtes

Temps d'exécution des requêtes analytiques (en secondes - Moins c'est mieux)



Analyse technique : L'écriture au format **Delta Lake** dans le Gold layer permet l'indexation, le caching automatique des données agrégées et l'optimisation des requêtes. Cela divise par 7 le temps de réponse par rapport à un stockage classique (CSV).

Planification JIRA & Jalons Du Projet

Jour 2 : Storage & Bronze

Déploiement ADLS Gen2.
Exécution du premier pipeline ADF
et validation de la couche Bronze
Parquet.

Jour 5 : BI & Soutenance

Import des données dans Power
BI, construction du dashboard
décisionnel et finalisation du
rapport.

Jour 1 : Cadrage & Ingestion

Rédaction de la doc technique.
Configuration de la base Azure
SQL et création du pipeline ADF.

Jours 3-4 : Spark & Silver/Gold

Mise en place Databricks.
Transformation des données en
Silver et calcul des indicateurs
agrégés en Gold.

DÉMONSTRATION TECHNIQUE

Des questions ?

Merci pour votre attention. Nous pouvons maintenant passer à la démonstration en direct du pipeline Azure Data Factory, de la structure ADLS Gen2 et du dashboard Power BI.

Pipeline Data Engineering Retail • Session Q&A (10 Min)

Image Sources



<https://learn.microsoft.com/en-us/azure/architecture/solution-ideas/media/azure-databricks-modern-analytics-architecture.svg>

Source: learn.microsoft.com



https://miro.medium.com/v2/resize:fit:1400/0*JxBpkbdv59eV-D57

Source: lakshmanok.medium.com