

Rapport Détaillé : Architecture de Données du Projet

Line Spacing: 1.15

1. Azure SQL Database

Définition

Azure SQL Database est un service de base de données relationnelle managé (PaaS) basé sur la dernière version stable du moteur de base de données Microsoft SQL Server. Il prend en charge de manière native les structures relationnelles, le langage T-SQL, ainsi que les formats JSON, spatiaux et XML.

Cas d'usage



- Stockage transactionnel (OLTP) pour les applications métier nécessitant une haute disponibilité.
- Base de données opérationnelle servant de point de départ ou de destination pour des flux d'intégration de données d'entreprise.

Avantages

- **SaaS / PaaS managé** : Élimine la gestion des infrastructures matérielles, les correctifs logicielles et les sauvegardes.
- **Mise à l'échelle automatique** : Ajustement dynamique des ressources de calcul (DTU ou vCore).
- **Sécurité intégrée** : Chiffrement des données au repos et en transit, détection des menaces et masquage dynamique.

Rôle dans le projet

Dans ce projet, Azure SQL Database fait office de source de données relationnelle principale (ou cible de synchronisation), stockant les données d'entreprise et d'inventaire essentielles qui alimentent les pipelines d'analyse globale.



2. Azure Data Lake Storage (ADLS Gen2)

Fonctionnement et Espace de noms hiérarchique

Azure Data Lake Storage Gen2 fusionne les capacités d'un système de fichiers haute performance avec l'évolutivité et le coût optimisé d'Azure Blob Storage. Sa fonctionnalité clé est l'**Espace de noms hiérarchique (Hierarchical Namespace)**, qui organise les objets (blobs) en une véritable hiérarchie de répertoires et de sous-dossiers, optimisant radicalement les performances des requêtes analytiques et de traitement de données de masse.

Notion de Container

Un conteneur agit comme la racine logique au sein du compte de stockage, regroupant les ensembles de données et permettant d'appliquer des politiques de sécurité et des contrôles

d'accès RBAC/ACL globales.

Architecture Medallion (Bronze, Silver, Gold)

L'organisation des données suit l'approche moderne du Lakehouse à travers trois couches progressives :

- **Couche Bronze (Données brutes)** : Stockage des données d'origine de manière brute, telles qu'elles proviennent des sources (ex: formats JSON, CSV). Aucune transformation n'est appliquée.
- **Couche Silver (Données nettoyées et enrichies)** : Les données sont nettoyées, filtrées, structurées et converties dans un format optimisé (comme le format Delta Lake ou Parquet) pour le traitement.
- **Couche Gold (Données agrégées pour le décisionnel)** : Les données sont transformées en modèles métiers agrégés et prêtes à être consommées directement par des outils de reporting comme Power BI ou des entrepôts de données SQL.

The screenshot shows the Microsoft Azure portal interface for a storage account named 'minasto'. The left sidebar contains navigation options like 'Journal d'activité', 'Étiquettes', 'Diagnostic et résolution des problèmes', etc. The main area displays the 'Bases' (Basics) tab for the storage account, showing details such as 'Groupe de ressource', 'Emplacement', 'Performance', 'Réplication', 'Genre de compte', 'État d'approvisionnement', and 'Créé'. Below this, the 'Propriétés' (Properties) section is visible, showing 'Data Lake Storage' settings and 'Sécurité' (Security) options.

The screenshot shows the Microsoft Azure portal interface for a container named 'minaconte'. The left sidebar contains navigation options like 'Diagnostic et résolution des problèmes', 'Contrôle d'accès (IAM)', and 'Paramètres'. The main area displays the 'Vue d'ensemble' (Overview) tab for the container, showing the 'Méthode d'authentification' (Authentication method) and a list of blobs. The blobs are listed in a table with columns: 'Nom', 'Dernière modification', 'Niveau d'accès', 'Type d'objet bl...', 'Taille', and 'État du bail'.

Nom	Dernière modification	Niveau d'accès	Type d'objet bl...	Taille	État du bail
[...]					
csv	05/06/2026 16:06:07				
sales_by_date	05/06/2026 16:05:58				
sales_by_product	05/06/2026 16:05:54				
sales_by_store	05/06/2026 16:06:03				

Microsoft Azure

Rechercher dans les ressources, services et documents (G+)

Copilot

melaacharate.ext@simp...
SIMPLONINFORMATIONS.CO (SIM...

Accueil > minasto | Conteneurs

minaconte

Conteneur

Rechercher

Ajouter un répertoire

Charger

Actualiser

Supprimer

Copier

Coller

Renommer

Acquérir le bail

Résilier le bail

minaconte > branze

Méthode d'authentification : Clé d'accès (Basculer vers le compte d'utilisateur Microsoft Entra)

Rechercher les objets blobs par préfixe (respect de la casse)

Afficher uniquement les objets actifs

Affichage de tous les éléments 4

☐	Nom	Dernière modification	Niveau d'accès	Type d'objet bl...	Taille	État du bail
☐	[.]					...
☐	customers	03/06/2026 10:57:06				...
☐	products	03/06/2026 10:57:14				...
☐	store	03/06/2026 10:57:37				...
☐	transaction	03/06/2026 10:57:32				...

Activer Windows
Accédez aux paramètres pour activer Windows.

Ajouter ou supprimer des favoris en appuyant sur
Ctrl+Shift+F

Microsoft Azure

Rechercher dans les ressources, services et documents (G+)

Copilot

melaacharate.ext@simp...
SIMPLONINFORMATIONS.CO (SIM...

Accueil > minasto | Conteneurs

minaconte

Conteneur

Rechercher

Ajouter un répertoire

Charger

Actualiser

Supprimer

Copier

Coller

Renommer

Acquérir le bail

Résilier le bail

minaconte > branze > products

Méthode d'authentification : Clé d'accès (Basculer vers le compte d'utilisateur Microsoft Entra)

Rechercher les objets blobs par préfixe (respect de la casse)

Afficher uniquement les objets actifs

Affichage de tous les éléments 1

☐	Nom	Dernière modification	Niveau d'accès	Type d'objet bl...	Taille	État du bail
☐	[.]					...
☐	dbo.products.parquet	03/06/2026 15:15:25	Chaud (déduit)	Objet blob de ...	1.27 KiB	Disponible

Activer Windows
Accédez aux paramètres pour activer Windows.

Ajouter ou supprimer des favoris en appuyant sur
Ctrl+Shift+F

Microsoft Azure

Rechercher dans les ressources, services et documents (G+)

Copilot

melaacharate.ext@simp... SIMPLONFORMATIONS.CO (SIM...)

Accueil > minasto | Conteneurs

minaconte ...

Conteneur

Rechercher

+ Ajouter un répertoire ↑ Charger Actualiser | Supprimer Copier Coller Renommer Acquérir le bail Résilier le bail ...

minaconte > silver

Méthode d'authentification : Clé d'accès (Basculer vers le compte d'utilisateur Microsoft Entra)

Rechercher les objets blobs par préfixe (respect de la casse)

Affichage de tous les éléments 1

☐	Nom	Dernière modification	Niveau d'accès	Type d'objet bl...	Taille	État du bail
☐	[.]					...
☐	sales_silver	05/06/2026 16:05:44				...

Activer Windows

Accédez aux paramètres pour activer Windows.

Ajouter ou supprimer des favoris en appuyant sur Ctrl+Shift+F

Microsoft Azure

Rechercher dans les ressources, services et documents (G+)

Copilot

melaacharate.ext@simp... SIMPLONFORMATIONS.CO (SIM...)

Accueil > minasto | Conteneurs

minaconte ...

Conteneur

Rechercher

+ Ajouter un répertoire ↑ Charger Actualiser | Supprimer Copier Coller Renommer Acquérir le bail Résilier le bail ...

minaconte > silver > sales_silver

Méthode d'authentification : Clé d'accès (Basculer vers le compte d'utilisateur Microsoft Entra)

Rechercher les objets blobs par préfixe (respect de la casse)

Affichage de tous les éléments 2

☐	Nom	Dernière modification	Niveau d'accès	Type d'objet bl...	Taille	État du bail
☐	[.]					...
☐	_delta_log	05/06/2026 16:05:44				...
☐	part-00000-496f8f19-7b9e-4416...	05/06/2026 16:05:46	Chaud (déduit)	Objet blob de ...	4.55 KiB	Disponible

Activer Windows

Accédez aux paramètres pour activer Windows.

Ajouter ou supprimer des favoris en appuyant sur Ctrl+Shift+F

3. Azure Data Factory (ADF)


Définition et Cas d'usage ETL / ELT

Azure Data Factory est un service cloud d'intégration de données totalement managé, conçu pour orchestrer et automatiser le mouvement et la transformation des données à grande échelle à travers des architectures hybrides (ETL ou ELT).

Concepts Clés

- **Pipelines** : Regroupements logiques d'activités qui accomplissent ensemble une tâche d'intégration de données.
- **Linked Services (Services liés)** : Chaînes de connexion définissant la liaison sécurisée vers les sources de données externes.

- **Datasets (Jeux de données)** : Structures nommées pointant directement vers les données utilisées au sein d'une activité.
- **Copy Activity (Activité de copie)** : Composant cœur d'ADF permettant le déplacement performant de données entre un magasin source et un magasin récepteur.



4. Databricks Community Edition

Présentation et Traitement distribué

Databricks est une plateforme d'analyse unifiée basée sur Apache Spark, optimisée pour le Cloud. La version Community Edition offre un environnement collaboratif gratuit permettant de concevoir, tester et valider des architectures Big Data.

Notebooks

Interface interactive web permettant d'écrire et d'exécuter du code de manière itérative en utilisant plusieurs langages (Python, SQL, Scala, R) sur la même plateforme.

Spark DataFrames

Structures de données bidimensionnelles distribuées en mémoire, organisées en colonnes nommées, fournissant une API puissante pour manipuler de larges volumes de données de manière hautement optimisée.

Cas d'usage

Principalement utilisé pour le nettoyage des données, les transformations complexes entre les couches de l'architecture Medallion, et la préparation des données pour les algorithmes avancés de Data Science.