

Rapport Détaillé : Architecture de Données du Projet

Line Spacing: 1.15

1. Azure SQL Database

Définition

Azure SQL Database est un service de base de données relationnelle managé (PaaS) basé sur la dernière version stable du moteur de base de données Microsoft SQL Server. Il prend en charge de manière native les structures relationnelles, le langage T-SQL, ainsi que les formats JSON, spatiaux et XML.

Cas d'usage



- Stockage transactionnel (OLTP) pour les applications métier nécessitant une haute disponibilité.
- Base de données opérationnelle servant de point de départ ou de destination pour des flux d'intégration de données d'entreprise.

Avantages

- **SaaS / PaaS managé** : Élimine la gestion des infrastructures matérielles, les correctifs logicielles et les sauvegardes.
- **Mise à l'échelle automatique** : Ajustement dynamique des ressources de calcul (DTU ou vCore).
- **Sécurité intégrée** : Chiffrement des données au repos et en transit, détection des menaces et masquage dynamique.

Rôle dans le projet

Dans ce projet, Azure SQL Database fait office de source de données relationnelle principale (ou cible de synchronisation), stockant les données d'entreprise et d'inventaire essentielles qui alimentent les pipelines d'analyse globale.



2. Azure Data Lake Storage (ADLS Gen2)

Fonctionnement et Espace de noms hiérarchique

Azure Data Lake Storage Gen2 fusionne les capacités d'un système de fichiers haute performance avec l'évolutivité et le coût optimisé d'Azure Blob Storage. Sa fonctionnalité clé est l'**Espace de noms hiérarchique (Hierarchical Namespace)**, qui organise les objets (blobs) en une véritable hiérarchie de répertoires et de sous-dossiers, optimisant radicalement les performances des requêtes analytiques et de traitement de données de masse.

Notion de Container


Un conteneur agit comme la racine logique au sein du compte de stockage, regroupant les ensembles de données et permettant d'appliquer des politiques de sécurité et des contrôles

d'accès RBAC/ACL globales.

Architecture Medallion (Bronze, Silver, Gold)

L'organisation des données suit l'approche moderne du Lakehouse à travers trois couches progressives :

- **Couche Bronze (Données brutes)** : Stockage des données d'origine de manière brute, telles qu'elles proviennent des sources (ex: formats JSON, CSV). Aucune transformation n'est appliquée.
- **Couche Silver (Données nettoyées et enrichies)** : Les données sont nettoyées, filtrées, structurées et converties dans un format optimisé (comme le format Delta Lake ou Parquet) pour le traitement.
- **Couche Gold (Données agrégées pour le décisionnel)** : Les données sont transformées en modèles métiers agrégés et prêtes à être consommées directement par des outils de reporting comme Power BI ou des entrepôts de données SQL.



3. Azure Data Factory (ADF)


Définition et Cas d'usage ETL / ELT

Azure Data Factory est un service cloud d'intégration de données totalement managé, conçu pour orchestrer et automatiser le mouvement et la transformation des données à grande échelle à travers des architectures hybrides (ETL ou ELT).

Concepts Clés

- **Pipelines** : Regroupements logiques d'activités qui accomplissent ensemble une tâche d'intégration de données.
- **Linked Services (Services liés)** : Chaînes de connexion définissant la liaison sécurisée vers les sources de données externes.
- **Datasets (Jeux de données)** : Structures nommées pointant directement vers les données utilisées au sein d'une activité.

- **Copy Activity (Activité de copie)** : Composant cœur d'ADF permettant le déplacement performant de données entre un magasin source et un magasin récepteur.



4. Databricks Community Edition

Présentation et Traitement distribué

Databricks est une plateforme d'analyse unifiée basée sur Apache Spark, optimisée pour le Cloud. La version Community Edition offre un environnement collaboratif gratuit permettant de concevoir, tester et valider des architectures Big Data.

Notebooks

Interface interactive web permettant d'écrire et d'exécuter du code de manière itérative en utilisant plusieurs langages (Python, SQL, Scala, R) sur la même plateforme.

Spark DataFrames

Structures de données bidimensionnelles distribuées en mémoire, organisées en colonnes nommées, fournissant une API puissante pour manipuler de larges volumes de données de manière hautement optimisée.

Cas d'usage

Principalement utilisé pour le nettoyage des données, les transformations complexes entre les couches de l'architecture Medallion, et la préparation des données pour les algorithmes avancés de Data Science.